SPRAWOZDANIE
Nauka o danych I - Moduł 1

Uniwersytet Bielsko-Bialski

Imię i nazwisko: Dominika Duraj
Numer indeksu: 66188
Przedmiot: Nauka o danych I
Temat: Analiza zbioru Students Performance in Exams

Rok akademicki: 2026/2027

1. Cel ćwiczenia

Celem ćwiczenia było przećwiczenie podstaw pracy z językiem Python, biblioteką pandas oraz podstawowymi funkcjami statystycznymi. Zadania obejmowały wczytywanie i tworzenie ramek danych, podgląd i czyszczenie danych, wybieranie oraz filtrowanie rekordów, operacje na kolumnach, agregację, tabele przestawne, wizualizację danych, łączenie ramek oraz obliczanie wybranych miar statystycznych.

2. Wykorzystany zbiór danych

Do wykonania ćwiczenia wykorzystano publiczny zbiór „Students Performance in Exams" opublikowany w serwisie Kaggle przez użytkownika spscientist.

Identyfikator zbioru Kaggle Hub: spscientist/students-performance-in-exams

Źródło: https://www.kaggle.com/datasets/spscientist/students-performance-in-exams

Zbiór zawiera 1000 rekordów i 8 kolumn. Opisuje wyniki uczniów z matematyki, czytania i pisania oraz wybrane informacje o uczniach, takie jak płeć, grupa etniczna, poziom wykształcenia rodziców, rodzaj lunchu i udział w kursie przygotowawczym.

W zbiorze występuje pięć kolumn kategorycznych i trzy kolumny liczbowe: math score, reading score oraz writing score. W analizowanym zbiorze nie stwierdzono brakujących wartości.

3. Wykonanie zadań - część A: pandas

3.1. Wczytanie i tworzenie ramki danych (zadania 1-5)

Zaimportowano bibliotekę pandas. Utworzono przykładowe ramki danych ze słownika oraz listy list. Następnie pobrano zbiór z Kaggle Hub i wczytano plik CSV do ramki df. Wykonano również transpozycję ramki danych.

3.2. Podgląd i informacje o danych (zadania 6-11)

Wyświetlono pierwsze i ostatnie 10 wierszy, informacje o typach kolumn i liczbie niepustych wartości, wymiary ramki oraz statystyki opisowe kolumn liczbowych i kategorycznych. Ramka zawiera 1000 wierszy i 8 kolumn.

3.3. Czyszczenie danych (zadanie 12)

Wykonano usunięcie brakujących wartości za pomocą dropna(). Kontrola liczby braków po tej operacji wykazała, że w analizowanym zbiorze nie było wartości brakujących.

3.4. Wybór wierszy i kolumn (zadania 13-17)

Przedstawiono wybieranie danych po nazwach kolumn i indeksach wierszy z użyciem m.in. loc oraz iloc. Zastosowano filtrowanie według jednego warunku, kilku warunków jednocześnie oraz wyszukiwanie i wykluczanie rekordów zawierających określone słowo w kolumnie kategorycznej.

3.5. Operacje na kolumnach (zadania 18-20)

Utworzono kolumnę average score jako średnią z wyników matematyki, czytania i pisania. Przećwiczono usuwanie kolumny na kopii ramki danych oraz zmianę nazwy kolumny.

3.6. Zapis i podstawowe agregacje (zadania 21-28)

Zapisano ramkę danych do pliku CSV. Obliczono średnią, minimum i maksimum wybranej kolumny, liczbę rekordów, wartości unikatowe i częstość ich występowania. Posortowano dane rosnąco i malejąco oraz wyświetlono rekordy o 10 największych i najmniejszych wynikach, także po zastosowaniu warunku.

3.7. Grupowanie i indeks złożony (zadania 29-32)

Pogrupowano dane według płci i obliczono średnie wyniki. Następnie zastosowano agregację kilku statystyk oraz utworzono kolumny z indeksem złożonym. Wyświetlono nazwy tych kolumn i posortowano wynik według średniej oceny z matematyki.

3.8. Tabele przestawne (zadania 33-35)

Utworzono tabelę przestawną przedstawiającą średni wynik z matematyki według płci i udziału w kursie przygotowawczym. Wyświetlono jej indeksy i kolumny. Przygotowano również tabelę przestawną z indeksem złożonym, uwzględniającą płeć, kurs przygotowawczy i rodzaj lunchu.

3.9. Wykresy (zadania 36-39)

Zaimportowano matplotlib.pyplot. W skrypcie Python wykresy wyświetlano przez plt.show(); polecenie %matplotlib inline jest przeznaczone dla środowiska notebookowego. Przygotowano wykres słupkowy na podstawie tabeli przestawnej oraz histogram wyników z matematyki.

3.10. Łączenie danych i kolumny obliczane (zadania 40-43)

Przedstawiono łączenie ramek danych metodami merge i concat. Dodano kolumnę będącą sumą trzech wyników oraz kolumnę obliczaną z użyciem funkcji lambda. Pokazano odczyt dużego pliku w częściach z argumentem chunksize.

4. Wykonanie zadań - część B: funkcje statystyczne

Wybrane miary obliczono na kolumnie math score za pomocą pandas i numpy. Dla odchylenia standardowego i wariancji w numpy zastosowano ddof=1, aby uzyskać wynik zgodny z domyślnym sposobem obliczania tych miar przez pandas.

Miara	Wynik	Interpretacja
Średnia (math score)	66,089	Przeciętny wynik z matematyki wynosi około 66 punktów.
Mediana (math score)	66,000	Połowa uczniów uzyskała wynik nie większy niż 66 punktów, a połowa nie mniejszy.
Odchylenie standardowe	15,163	Wyniki są przeciętnie dość wyraźnie rozproszone wokół średniej.
Wariancja	229,919	Wariancja jest kwadratem odchylenia standardowego; opisuje rozproszenie w jednostkach podniesionych do kwadratu.

Korelacja Pearsona (math/reading)	0,81758	Występuje silna dodatnia zależność liniowa: wyższym wynikom z matematyki zwykle towarzyszą wyższe wyniki z czytania.
Kowariancja (math/reading)	180,99896	Dodatnia wartość oznacza, że obie zmienne mają tendencję do wzrostu razem; wynik zależy od skali zmiennych.

Średnia i mediana wyników z matematyki są do siebie zbliżone (66,089 i 66), co wskazuje, że te dwie miary położenia centralnego dają podobny obraz typowego wyniku. Odchylenie standardowe wynosi około 15,16 punktu, co pokazuje zauważalne zróżnicowanie wyników.

Korelacja Pearsona między wynikiem z matematyki i czytania wynosi około 0,818, czyli wskazuje na silną dodatnią zależność liniową. Kowariancja również jest dodatnia, co potwierdza wspólny kierunek zmian obu zmiennych. W przeciwieństwie do korelacji kowariancja nie jest standaryzowana i jej wartość zależy od jednostek oraz skali danych.

5. Podsumowanie dwóch kolumn

W końcowym podsumowaniu zestawiono wyniki z matematyki i czytania. Dla obu kolumn obliczono średnią, medianę i odchylenie standardowe, a następnie korelację i kowariancję. Wyniki wskazują, że oceny z obu przedmiotów są ze sobą silnie i dodatnio powiązane. Uczniowie osiągający wyższe wyniki z matematyki mają zwykle również wyższe wyniki z czytania.

6. Wykresy i zrzuty ekranu

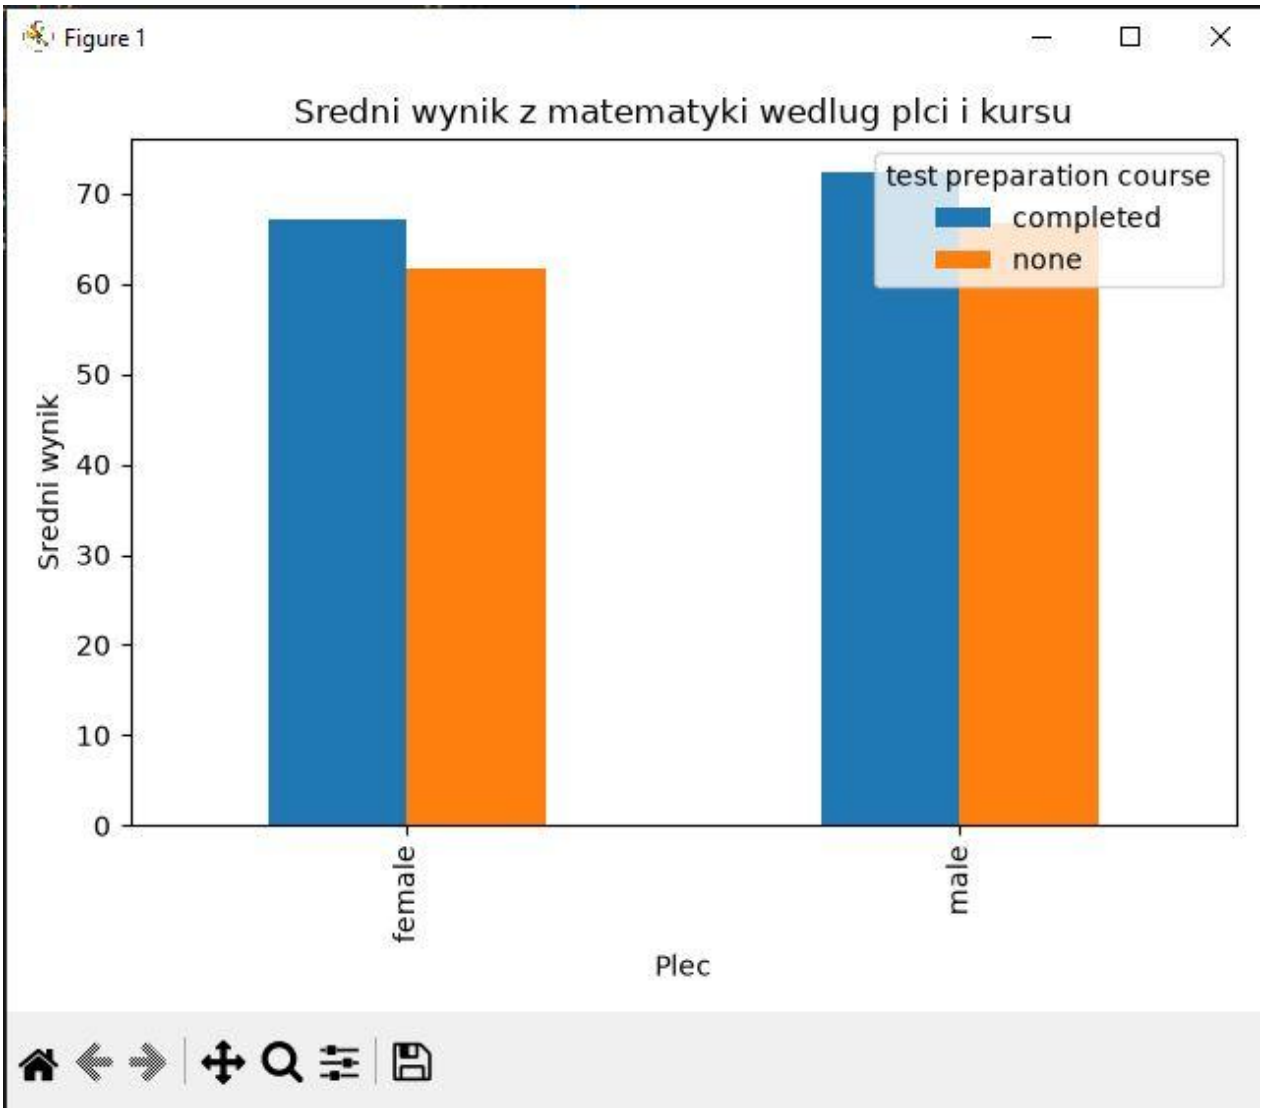
Rysunek 1. Podgląd danych - df.head()

```
[8 rows x 1000 columns]
   gender race/ethnicity parental level of education         lunch test preparation course  math score  reading score  writing score
0  female        group B           bachelor's degree      standard                    none          72             72             74
1  female        group C                some college      standard               completed          69             90             88
2  female        group B             master's degree      standard                    none          90             95             93
3    male        group A          associate's degree  free/reduced                    none          47             57             44
4    male        group C                some college      standard                    none          76             78             75
5  female        group B          associate's degree      standard                    none          71             83             78
6  female        group B                some college      standard               completed          88             95             92
7    male        group B                some college  free/reduced                    none          40             43             39
8    male        group D                 high school  free/reduced               completed          64             64             67
9  female        group B                 high school  free/reduced                    none          38             60             50
```

Rysunek 2. Informacje o danych - df.info()

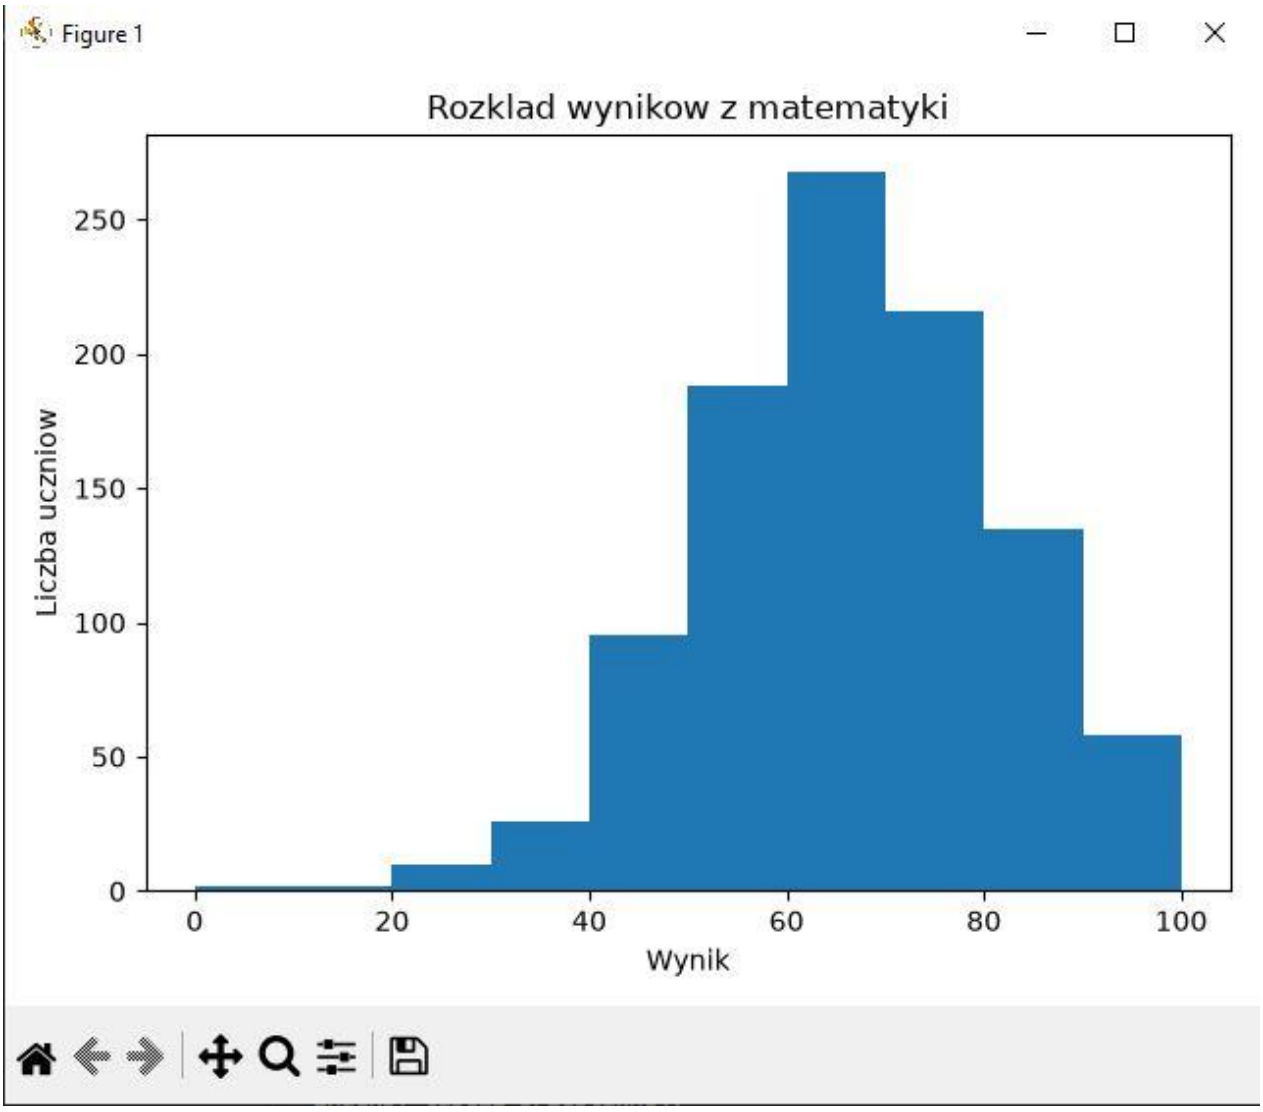
```
<class 'pandas.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 8 columns):
 #   Column                       Non-Null Count  Dtype
---  ------                       --------------  -----
 0   gender                       1000 non-null   str
 1   race/ethnicity               1000 non-null   str
 2   parental level of education  1000 non-null   str
 3   lunch                        1000 non-null   str
 4   test preparation course      1000 non-null   str
 5   math score                   1000 non-null   int64
 6   reading score                1000 non-null   int64
 7   writing score                1000 non-null   int64
dtypes: int64(3), str(5)
memory usage: 62.6 KB
```

Rysunek 3. Wykres słupkowy z tabeli przestawnej (zadanie 38)



Komentarz: Uczniowie, którzy ukończyli kurs przygotowawczy, uzyskali wyższy średni wynik z matematyki w obu grupach płci.

Rysunek 4. Histogram wyników z matematyki (zadanie 39)



Komentarz: Najwięcej wyników mieści się w przedziale 60-70 punktów (268 uczniów), a najmniej w przedziałach 0-10 i 10-20 (po 2 uczniów).

7. Informacja o wykorzystaniu narzędzi AI

Podczas realizacji ćwiczenia korzystano z ChatGPT jako narzędzia pomocniczego. Narzędzie służyło do wyjaśniania działania wybranych funkcji pandas i numpy, pomocy w analizie komunikatów z uruchomienia programu oraz uporządkowania treści sprawozdania. Kod był uruchamiany lokalnie, a uzyskane wyniki i wykresy pochodziły z wykorzystanego zbioru danych.

8. Wnioski końcowe

Wykonanie zadań pozwoliło przećwiczyć podstawowe operacje na ramkach danych w pandas, w tym filtrowanie, grupowanie, agregowanie, tworzenie tabel przestawnych i wykresów. Analiza zbioru wykazała, że średni wynik z matematyki wynosi 66,089 punktu, a mediana 66 punktów. Wyniki

uczniów są zróżnicowane, co potwierdza odchylenie standardowe wynoszące około 15,16. Między wynikami z matematyki i czytania występuje silna dodatnia korelacja, co oznacza, że wyższy wynik z jednego z tych przedmiotów często współwystępuje z wyższym wynikiem z drugiego.